



Sistema de Recomendação para clientes de vídeo locadoras baseado em redes Kohonen

Trabalho de Conclusão de Curso
Engenharia da Computação

Anderson Berg dos Santos Dantas

Orientador: Prof. Fernando Buarque de Lima Neto, PhD



Anderson Berg dos Santos Dantas

Sistema de Recomendação para clientes de vídeo locadoras baseado em redes Kohonen

Monografia apresentada como requisito parcial para obtenção do diploma de Bacharel em Engenharia da Computação pela Escola Politécnica de Pernambuco - Universidade de Pernambuco.

Orientador:

Prof. Fernando Buarque de Lima Neto, PhD

DEPARTAMENTO DE SISTEMAS E COMPUTAÇÃO
ESCOLA POLITÉCNICA DE PERNAMBUCO
UNIVERSIDADE DE PERNAMBUCO

Recife - PE, Brasil

Novembro de 2009

Resumo

Abstract

Dedicatória

Agradecimientos

Sumário

Lista de Figuras

Lista de Tabelas

1	Introdução	p. 10
1.1	Caracterização do Problema	p. 10
1.2	Motivações	p. 11
1.3	Objetivos e Metas	p. 11
1.4	Organização do Documento	p. 11
1.4.1	Capítulo 2: Revisão Bibliográfica	p. 11
1.4.2	Capítulo 3: Modelo Proposto	p. 11
1.4.3	Capítulo 4: Configurações dos Experimentos e Análise dos Resultados	p. 12
1.4.4	Capítulo 5: Conclusão e Trabalhos Futuros	p. 12
2	Fundamentação Teórica	p. 13
2.1	Sistemas de Recomendação	p. 13
2.1.1	Técnicas de recomendação	p. 16
2.1.1.1	Filtragem baseada em conteúdo	p. 16
2.1.1.2	Filtragem colaborativa	p. 18
2.1.1.3	Filtragem híbrida	p. 19
2.2	Mapas auto-organizáveis	p. 20
3	Modelo proposto	p. 25

3.1	Visão Geral	p. 25
3.2	Implementação do modelo	p. 26
3.3	Funcionamento do modelo	p. 27
4	Experimento e Análise de Resultados	p. 28
4.1	Base de dados	p. 28
5	Conclusões	p. 30
	Referências	p. 31

Lista de Figuras

1	Avaliações de usuários no sítio da Amazon.com para uma câmera fotográfica.	p. 15
2	Recomendações da Amazon.com de acordo com o histórico do cliente. .	p. 15
3	Associação de produtos por clientes na Amazon.com	p. 16
4	Córtex cerebral humano	p. 21
5	Rede SOM bidimensional	p. 21
6	Função chapéu mexicano	p. 22
7	Exemplo de vizinhança, onde o instante 2 é menor que o instante 1, que por sua vez é menor que o instante 0	p. 24
8	Diagrama de classes do modelo	p. 27

Lista de Tabelas

1 Introdução

1.1 Caracterização do Problema

A tecnologia, principalmente a internet, tem mudado a forma de fazer negócios na indústria do entretenimento. Vê-se atualmente, a migração do mercado físico para o virtual. Muitas lojas disponibilizam a venda dos seus produtos através de sítios na grande rede de computadores, outras, ainda, possuem apenas as lojas virtuais. Uma das vantagens dessas lojas é o fato de, por não precisar de um ambiente físico para vendas, o número de produtos oferecidos é muito maior (1).

Diante de tanta diversidade, o cliente, que vai adquirir um produto em sítios de comércio eletrônico, frequentemente precisa de auxílio para encontrar o que deseja. Além das ferramentas de busca, as grandes lojas virtuais disponibilizam uma forma de mostrar ao cliente produtos que podem interessá-lo, que é o sistema de recomendação. Os sistemas de recomendação podem sugerir produtos levando em consideração compras anteriores de determinado cliente ou através de opiniões de outros clientes. Desta feita, os sistemas de recomendação criam lojas personalizadas para cada cliente, incorporando algo muito importante para o negócio que é a fidelização. Em vídeo locadoras é comum a dificuldade de sugerir novos filmes para clientes, mesmo para os clientes mais antigos. É complicado se lembrar dos filmes já locados pelo cliente e quais foram suas preferências. Atualmente muitas locadoras de dvd estão disponibilizando locações através de páginas na internet com a vantagem da entrega a domicílio. Fato que dificulta ainda mais a obtenção de opiniões de terceiros pelo cliente. Sistemas de recomendação podem trazer todas as suas vantagens para vídeo locadoras tanto físicas como virtuais, auxiliando o cliente a fazer a melhor escolha. Isso leva a uma personalização da vídeo locadora na visão do cliente.

1.2 Motivações

O que motivou o presente trabalho foi a possibilidade de tornar a escolha de um filme para locação uma experiência mais simples e interessante. No sistema construído, o cliente pode visualizar suas antigas escolhas agrupadas convenientemente e então poder direcionar suas escolhas, tornando-o mais satisfeito com o serviço.

1.3 Objetivos e Metas

O objetivo deste trabalho é desenvolver um sistema de recomendação simples para clientes que frequentam vídeo locadoras. O sistema visa facilitar e agilizar a escolha de um filme pelo cliente, diminuindo as chances de desperdício de dinheiro em algo que não lhe agrada. Além de oferecer um serviço diferenciado ao cliente, a vídeo locadora irá se beneficiar pela fidelização do mesmo, já que ocorre uma personalização do serviço. Temos como meta construir um mapa auto-organizável de Kohonen distribuindo o histórico de locações de um determinado cliente de maneira que este possa visualizar todo seu histórico de forma gráfica. Quando o cliente desejar realizar uma locação o mapa irá mostrar o lugar que este novo filme se insere e seus principais vizinhos que caracterizam os filmes mais relacionados àquele.

1.4 Organização do Documento

1.4.1 Capítulo 2: Revisão Bibliográfica

Neste capítulo serão feitas as revisões da literatura sobre diversos conhecimentos fundamentais para a compreensão do restante do trabalho.

1.4.2 Capítulo 3: Modelo Proposto

Será apresentada a proposta central do modelo, além do algoritmo que foi desenvolvido.

1.4.3 Capítulo 4: Configurações dos Experimentos e Análise dos Resultados

Neste capítulo serão expostos os experimentos realizados com o modelo e os resultados obtidos para comprovar a funcionalidade do modelo.

1.4.4 Capítulo 5: Conclusão e Trabalhos Futuros

Considerações finais e propostas de continuidade do trabalho.

2 *Fundamentação Teórica*

Neste capítulo iremos apresentar os principais conceitos que ajudarão na compreensão do resto do documento. Primeiramente serão abordadas as características de sistemas de recomendação estabelecidos na literatura. Também serão abordadas as principais técnicas de recomendação, apontando suas vantagens, principais problemas e soluções propostas por diversos autores a fim de solucionar essas falhas. Posteriormente serão apresentados os mapas auto-organizáveis, em especial os mapas de Kohonen, definindo sua arquitetura e o algoritmo de aprendizado.

2.1 Sistemas de Recomendação

O uso de sistemas informatizados, principalmente da internet, resulta em um grande volume de informação sendo criada e transmitida no mundo todo (2). Um estudo realizado em 2003 por pesquisadores da Universidade da Califórnia (3) estimou que cinco exabytes de informação foram criados no ano de 2002, onde a maior parte é armazenada em dispositivos magnéticos, em especial discos rígidos. Nasceu, então, a necessidade da criação de mecanismos que tenham a capacidade de filtrar ou recuperar rapidamente informação. Com o objetivo de facilitar a busca por informação foram criados mecanismos que pudesse indexar documentos na internet e, rapidamente, recuperá-los, trazendo ao usuário aquilo que ele precisa. Tais mecanismos são as ferramentas de busca como o google (www.google.com), que seleciona documentos na internet a partir de critérios que o usuário expressa através de palavras-chave.

O comércio, principalmente a indústria do entretenimento, tem se beneficiado com a evolução da tecnologia. As lojas não precisam mais ter espaço físico, é possível realizar vendas e fazer negociações com segurança através da internet. A *Itunes Store* possui mais de 10 milhões de músicas disponíveis para venda através de *download*. As grandes lojas de departamentos possuem lojas virtuais para comércio eletrônico, algumas delas nem possuem lojas físicas, apenas os sítios na internet onde podem vender seus produtos. Ca-

sos de sucesso no Brasil são as Americanas.com (www.americanas.com.br) e o Submarino (www.submarino.com.br). Sem a necessidade de ter espaço físico ou prateleiras, os itens que podem ser colocados à venda são de um número superior se comparado a uma loja convencional (1). Diante de tantas possibilidades, como ir em busca da melhor informação? Qual produto vale a pena adquirir? Qual filme ou música escolher? Frequentemente as pessoas procuram opiniões de terceiros, como amigos e familiares que já tiveram uma experiência com determinado produto ou serviço. Podem, ainda, procurar por resenhas em jornais e revistas, ou pedir a opinião do dono de uma livraria ou vídeo locadora. Porém, nenhum deles pode fazer recomendações de acordo com preferências pessoais.

Filtrar toda a informação recebida por um usuário, raramente é uma tarefa simples e eficiente. Um dos primeiros sistemas de filtragem criados foi o Tapestry (4). Este sistema filtrava documentos enviados para a caixa de *emails* de um usuário. O Tapestry analisava, não somente o conteúdo dos textos, mas também o interesse que outros usuários tinham por esses documentos. Os idealizadores desse projeto cunharam o termo "filtragem colaborativa", propondo um sistema onde a filtragem de documentos seria realizada com auxílio de grupos de pessoas com o mesmo interesse. Atualmente, os sítios de comércio eletrônico disponibilizam para seus clientes ferramentas computacionais com o objetivo de auxiliá-los no momento da compra. Essas ferramentas caracterizam os sistemas de recomendação. Tais sistemas consistem em mostrar ao usuário produtos que sejam de seu interesse, alguns sistemas ainda fornecem opiniões de outros clientes sobre aqueles produtos. Um dos maiores exemplos de sítios de comércio eletrônico que fazem bom uso de sistemas de recomendação é a Amazon.com (www.amazon.com).

Auxiliar o cliente mostrando produtos relacionados às suas preferências é uma forma de personalização. A personalização é uma característica do *marketing* direto. Diferente do *marketing* de massa, cujo objetivo é alcançar o maior número de pessoas através dos diversos tipos de mídia, o *marketing* direto é mais pessoal, ele se interessa pelo indivíduo. Personalizar resulta na fidelização do cliente, que é um grande diferencial entre empresas concorrentes (5). Um mini-curso de sistemas de recomendação ministrado no V Encontro Nacional de Inteligência Artificial, no ano de 2005, por Eliseo Reategui e Sílvia Cazella (6) cita algumas estratégias utilizadas pelos sítios de comércio eletrônico para recomendação de produtos:

- Listas de recomendação: A loja mantém listas de produtos, como itens mais vendidos, itens que têm a melhor avaliação entre os clientes ou lista de presentes, entre outros.

- Avaliação de usuários: Consiste em se obter notas do produto por clientes que já o adquiriram, além dessa avaliação usuários podem deixar comentários sobre determinado produto (Figura 1).
- Suas recomendações: O sítio oferece alguns produtos baseado em interesses do cliente. Aqui pode-se ter dois tipos de recomendação: implícita, onde o sítio oferece produtos de acordo com o histórico de compras do cliente, ou explícita, onde o usuário determina quais são suas preferências (Figura 2).
- "Clientes que adquiriram um produto X, também compraram Y": O sistema de recomendação cria associações entre produtos avaliados por usuário para oferecer produtos relacionados ao que o cliente está adquirindo no momento (Figura 3).
- Associação por conteúdo: Este tipo de recomendação é feita baseado no conteúdo de determinado item. Por exemplo: Os livros: Redes de Computadores e Programação em Java são frequentemente vendidos em conjunto.

Customer Reviews

Average Customer Rating

★★★★☆ (131 customer reviews)

5 star: (97)
4 star: (18)
3 star: (8)
2 star: (6)
1 star: (2)

Battery life★★★★☆ (63)

Ease of use★★★★☆ (63)

Features★★★★☆ (63)

Picture quality★★★★☆ (63)

> [See and rate all 13 attributes.](#)

Figura 1: Avaliações de usuários no sítio da Amazon.com para uma câmera fotográfica.

Your Recent History (What's this?)

Recently Viewed Items


[Kindle Wireless Reading Device \(6" Display...](#) by Amazon

> [View and edit your browsing history](#)

Continue shopping: Customers Who Bought Items in Your Recent History Also Bought



2-Year Extended Warranty for Kindle (6" Display...
★★★★☆ (8) \$65.00
[Fix this recommendation](#)



Amazon Kindle Leather Cover (Fits 6" Display...
★★★★☆ (2,044) \$29.99
[Fix this recommendation](#)



Built Neoprene Kindle Sleeve (Fits 6" Display...
★★★★☆ (2) \$24.99
[Fix this recommendation](#)

Figura 2: Recomendações da Amazon.com de acordo com o histórico do cliente.



Figura 3: Associação de produtos por clientes na Amazon.com

2.1.1 Técnicas de recomendação

Diversas técnicas que pudessem identificar padrões de comportamento e filtragem de informação foram definidas na literatura com o objetivo de obter recomendações e personalização para o usuário. As três técnicas mais utilizadas em sistemas de recomendação são a filtragem baseada em conteúdo, a filtragem colaborativa e a filtragem híbrida, que procura conciliar as vantagens de duas ou mais técnicas atacando seus principais problemas.

2.1.1.1 Filtragem baseada em conteúdo

A filtragem baseada em conteúdo tem suas raízes no processo chamado de recuperação de informação, onde o usuário apresenta ao sistema um formulário e recebe, como resultado, documentos associados a esses critérios (7). O principal objetivo da recuperação de informação é encontrar documentos que correspondam a determinado critério de busca (8). Em um sistema de recuperação de informação, o usuário fornece ao sistema palavras-chave que representam seus interesses ou necessidades atuais na procura por informação. O sistema então, realiza uma busca por essas palavras em documentos armazenados numa base e retorna os documentos mais relevantes para os critérios informados.

Ao contrário da recuperação de informação, a filtragem de informação mantém o perfil do usuário filtrando todo novo item que é recebido relacionando-o a seus interesses. A filtragem de informação demonstra interesses a longo prazo, pois continua realizando a seleção de documentos de acordo com as preferências do usuário, enquanto a recuperação de informação, que seleciona documentos de acordo com um critério de pesquisa, representa interesses de curto prazo (9). Os atuais sistemas de recomendação têm sua origem nos sistemas de filtragem de informação. Em 1982, Peter Denning (10) já apontava para o problema do volume de informação produzida e transmitida, sendo necessária uma

atenção maior para o processo de controlar e filtrar toda essa informação. Filtragem de informação e filtragem baseada em conteúdo são termos semelhantes e ambos possuem o mesmo objetivo: filtrar itens através da análise do seu conteúdo (8).

Na filtragem baseada em conteúdo, as recomendações são feitas apenas baseadas em um perfil do usuário previamente construído. Esse perfil é individual e determinado a partir da análise do conteúdo de itens que o usuário qualificou ou mostrou algum interesse no passado (7). Quando o usuário de um sítio de comércio eletrônico, por exemplo, entra na página da loja e expõe suas necessidades através de palavras-chave na ferramenta de busca, ele está realizando uma recuperação de informação, pois o sistema vai procurar produtos que satisfaçam simplesmente os critérios apresentados no momento. Quando este mesmo sítio armazena o perfil do cliente e apresenta produtos semelhantes aos que este usuário mostrou interesse no passado, caracteriza uma filtragem de informação. Uma das técnicas mais populares para representação dos itens em sistemas de filtragem baseada em conteúdo é a TF-IDF (Term-frequency Inverse-Document-Frequency). Esta técnica realiza comparação e cálculo de similaridade a partir da frequência de ocorrência de palavras-chave nos textos (5). Para criação do perfil do usuário, normalmente são utilizadas técnicas de computação inteligente, que podem aprender o comportamento de determinado usuário, por exemplo, algoritmos de classificação podem indentificar e fazer a divisão entre itens que o usuário gosta e itens que ele não gosta (8). O *feedback* é muito importante na fase de aprendizado, podendo ser explícito, quando o usuário qualifica o item que lhe foi oferecido, ou implícito, quando o usuário demonstra interesse no item finalizando com a compra (2). Exemplos de sistemas que utilizam a filtragem baseada em conteúdo são o NewsWeeder (11) e o InfoFinder (12).

A filtragem baseada em conteúdo possui pontos positivos e negativos, dentre suas vantagens pode-se citar: (i) não é necessário que um novo item tenha algum tipo de qualificação, bastando apenas que este seja semelhante ao perfil do usuário e (ii) por avaliar a semelhança entre todos os itens, a filtragem baseada em conteúdo não se restringe a itens já avaliados por outros usuários. Os principais problemas apresentados pela filtragem baseada em conteúdo são: (i) as representações de conteúdo de um item não conseguem capturar alguns aspectos, como qualidade de um texto, no caso sistemas de recomendação de documentos, ou informações de multimídia, no caso de sistemas que recomendam páginas da internet (7); (ii) o segundo ponto negativo da filtragem baseada em conteúdo é a superespecialização. Como esse tipo de filtragem leva em consideração itens que o usuário já mostrou interesse, as recomendações ficam restritas a itens similares a itens já qualificados pelo usuário.

2.1.1.2 Filtragem colaborativa

A filtragem colaborativa é a técnica de recomendação mais comum e a mais largamente utilizada (13). A abordagem da filtragem colaborativa é recomendar itens baseados na similaridade entre usuários, deferentemente da filtragem baseada em conteúdo, que realiza similaridade entre itens. Basicamente, é formado um conjunto de usuários denominados "vizinhos mais próximos", que possuem itens classificados de forma semelhante ao usuário atual. Os itens que serão recomendados são itens que foram bem qualificados por esse grupo de usuários, partindo do pressuposto que esse grupo de usuários têm preferências em comum com o usuário atual. A priori, neste tipo de técnica nenhuma informação sobre os itens em si é conhecida, as recomendações são baseadas na semelhança entre os usuários (7). Segundo descreve (13): "O perfil de um usuário num sistema colaborativo consiste em um vetor de itens e suas qualificações, que é aperfeiçoado na medida que o usuário interage com o sistema ao longo do tempo."

Um dos primeiros sistemas a utilizar a filtragem colaborativa foi o Tapestry (4), já mencionado anteriormente neste trabalho. A ideia do Tapestry é fazer com que as pessoas colaborem entre si para realizar filtragens descrevendo suas percepções a documentos que leram. Essas percepções são armazenadas em comentários ou anotações que podem ser consultadas por qualquer outro usuário. Uma forma de utilização desse sistema seria um usuário buscar documentos que outro determinado usuário aprovou. Os principais representantes de sistemas que utilizam filtragem colaborativa, além do Tapestry, são o GroupLens (14), Ringo (15) e Belcore (16). Podem-se citar algumas vantagens deste tipo de técnica:

- Como as recomendações são baseadas em avaliações de outros usuários é possível tratar diferentes tipos de conteúdo, não somente documentos textuais.
- A qualidade das recomendações é superior se comparado a sistemas que utilizam filtragem baseada em conteúdo. A justificativa está no fato de sistemas automatizados não serem eficientes em analisar a qualidade de um produto, por exemplo, mas quando se baseia na avaliação de outros usuários é possível produzir recomendações de qualidade.

Algumas das desvantagens da filtragem colaborativa são:

- Se um novo item é introduzido no sistema, não será recomendado até que um dos usuários o avalie. O que traz outra consequência: se o número de usuários do sistema

é reduzido em relação à quantidade de itens, ocorre um problema de cobertura, ou seja, a coleção de itens que podem ser recomendados será resumida.

- Outro problema em sistemas utilizando filtragem colaborativa ocorre quando há um usuário cujas preferências diferem dos demais usuários, ou seja, não há vizinhos semelhantes ao usuário ativo, ocasionando em recomendações pobres.

2.1.1.3 Filtragem híbrida

A abordagem da filtragem híbrida consiste em associar duas ou mais técnicas de recomendação com o objetivo de tratar os principais problemas inerentes a cada uma delas. (13) realizou um estudo sobre sistemas de recomendação híbridos. Neste artigo ele aponta sete combinações possíveis entre técnicas de recomendação:

1. Ponderado: A avaliação de um item é a combinação do resultado de todas as técnicas presentes no sistema. O sistema P-Tango (17) é um exemplo de uso desta técnica. A proposta do P-Tango é combinar as recomendações da filtragem baseada em conteúdo e da filtragem colaborativa através de médias ponderadas. Os pesos são ajustados de acordo com o peso de cada recomendação, isto é, ao passo que o número de usuários e avaliações de um determinado item cresce, a filtragem colaborativa tem seu peso aumentado.
2. Alternado: O sistema se utiliza de um critério para alternar entre as técnicas de recomendação. Por exemplo, se uma filtragem baseada em conteúdo não retorna resultados satisfatórios, então a recomendação é feita com a filtragem colaborativa.
3. Misto: Neste tipo de combinação, o sistema apresenta recomendações de diferentes técnicas numa mesma listagem. O sistema PTV (18) utiliza a filtragem baseada em conteúdo baseado nas descrições de programas de TV e a filtragem colaborativa baseado na preferência de outros usuários, o resultado das recomendações é uma combinação dos resultados das duas filtragens.
4. Combinação de características: Trata informações de um tipo de recomendação como simples características que são utilizadas por outra técnica para retornar recomendações mais significativas. (19) apresenta um sistema de recomendação de filmes onde as informações da filtragem colaborativa (denominadas, neste artigo, características colaborativas) são influenciadas pelo conteúdo agregado aos filmes. Desta forma, é possível agrupar usuários semelhantes e que gostem do mesmo gênero de filmes.

5. Cascata: Nesta combinação, uma técnica, primeiramente, produz suas recomendações e uma segunda técnica é usada para refinar os resultados da anterior.
6. Acréscimo de característica: Primeiramente uma técnica é aplicada para gerar classificações para um item, então estas informações são incorporadas na técnica seguinte.
7. *Meta-level*: Esta abordagem utiliza o modelo criado por uma técnica como entrada para outra técnica. No acréscimo de característica, um modelo gera características para serem usadas como entrada para outro modelo, na abordagem *meta-level* o modelo completo é utilizado como entrada para outro modelo.

2.2 Mapas auto-organizáveis

O principal objetivo das redes neurais artificiais (RNAs) é aprender com o ambiente em que estão inseridas para adquirirem a capacidade de adaptação às mudanças nesse ambiente. O tipo de aprendizado das redes neurais pode ser dividido em duas classes: aprendizado supervisionado e aprendizado não-supervisionado. O método mais comumente utilizado é o aprendizado supervisionado, onde, além da entrada, a saída desejada para a rede são fornecidas por um supervisor externo (20). O objetivo é fazer o ajuste de parâmetros de forma que a rede possa representar novas entradas corretamente. O método de aprendizado supervisionado se limita, porém, a aplicações onde tanto os dados de entrada como as respostas desejadas são conhecidos. Algumas aplicações necessitam que o treinamento seja realizado sem um supervisor para a rede, todo o conhecimento deve ser adquirido somente através das entradas. Diversos algoritmos foram desenvolvidos para treinar redes sem supervisão, este trabalho irá tratar de um deles: os modelos *self-organizing* ou auto-organizáveis.

Os mapas *self-organizing*, SOM (*Self-organizing maps*) foram propostas por Teuvo Kohonen (21). A estrutura básica dessas redes é formada por uma camada de entrada, constituída de padrões fonte, e uma camada de saída que representa as entradas. Não há camadas escondidas (hidden layer) no modelo de mapas auto-organizáveis como em outros tipos de redes neurais. A inspiração para o desenvolvimento das redes SOM está no mapa topologicamente organizado do córtex cerebral de animais mais desenvolvidos. O córtex cerebral humano é organizado de acordo com funções específicas, como fala e visão (Figura 4). Desta forma, neurônios que lidam com o mesmo tipo de estímulo estão localizados próximos uns dos outros. O modelo de Kohonen consiste em um mapa, onde os nós ou nodos que estão topologicamente próximos respondem a estímulos semelhantes,

ou seja, padrões de entrada que possuem similaridade entre si.



Figura 4: Córtex cerebral humano

Na arquitetura de uma rede SOM, os nodos são dispostos em uma grade ou reticulado, geralmente bidimensional ou unidimensional, com raras exceções, há redes tridimensionais ou n-dimensionais. No modelo bidimensional, os neurônios estão organizados em linhas e colunas, como mostra a Figura 5. Cada nodo possui um conjunto de pesos que representam as sinapses do neurônio biológico, esses pesos são ajustados de maneira que o nodo represente um dado padrão de entrada. Os nodos de uma rede SOM funcionam como um extrator de características, quanto mais o vetor de pesos de um neurônio for semelhante a um padrão de entrada, maior será sua saída e mais representativo este nodo será para a entrada (20).




Figura 5: Rede SOM bidimensional

As redes SOM utilizam um processo de aprendizado competitivo, no qual os neurônios da camada de saída competem entre si para representar um dado padrão de entrada, assim, apenas um neurônio de saída ou neurônio por grupo estará ativo a qualquer instante

de tempo. O neurônio que se sobressai entre os outros para representar a entrada é chamado de vencedor e a competição é chamada de *winner-takes-all*, o vencedor leva tudo. Para implementar esta competição são normalmente utilizadas conexões laterais inibitórias entre os neurônios de saída. O modelo para esse tipo de conexão também provém das células do córtex cerebral, onde a ordenação topológica dos neurônios se dá graças ao *feedback* lateral entre as células. Em RNAs este *feedback* é modelado por uma função chamada chapéu mexicano. Segundo esta função, as interações laterais entre os neurônios podem ser divididas em três regiões distintas, como mostrado na Figura 6: (1) área excitatória, vizinhos que estão mais próximos ao neurônio atual; (2) área inibitória, vizinhos que estão fora da área anterior, mas incluídos numa segunda área; e (3) área levemente excitatória, que rodeia a área inibitória, esta terceira área geralmente é ignorada.




Figura 6: Função chapéu mexicano

Para simular o efeito da função chapéu mexicano, a rede SOM utiliza o conceito de vizinhança topológica dos neurônios vencedores. Quando um neurônio vence a competição e é o escolhido para representar o padrão de entrada, ele tem seus pesos ajustados de forma a se aproximar mais da entrada, com o conceito de vizinhos topológicos, além do neurônio vencedor ter seus pesos ajustados, os neurônios localizados na vizinhança também têm seus pesos ajustados.

Como dito anteriormente, o treinamento de redes SOM é competitivo e não-supervisionado. Primeiramente os pesos dos neurônios do mapa são inicializados com valores aleatórios, que serão ajustados ao longo do algoritmo de aprendizado, de forma que se aproximem dos padrões de entrada. Em seguida é apresentado um padrão p à rede, neste momento a rede define o neurônio que melhor representa esta entrada, caracterizando o neurônio vencedor. Para a escolha do neurônio vencedor é definida uma função de ativação que é baseada na distância entre o peso do neurônio e o vetor de entrada. A função de ativação

mais conveniente para a rede SOM é baseada na distância euclidiana (22), apresentada na equação 2.1:

$$y_j = \sum_{i=1}^n \|x_i - w_{ji}\| \quad (2.1)$$

onde y_j representa a saída do neurônio j , x é o vetor de entrada e w_{ji} é o peso do neurônio j associado ao elemento de entrada x_i .

O neurônio que possui a menor distância é escolhido como o vencedor e irá representar o padrão de entrada. Após essa escolha dá-se início ao processo de atualização dos pesos. Nesta fase o neurônio vencedor e os vizinhos definidos pelo raio ou área de vizinhança atualizam seus pesos. A fim de implementar a interação lateral, é definida uma região de vizinhança N_c , tendo como centro o neurônio c , estabelecido como vencedor pela função de ativação. Todos os neurônios internos a essa vizinhança terão os pesos atualizados, enquanto neurônios fora do limite serão deixados intactos. O valor do raio ou tamanho de N_c deve, inicialmente, ser alto e diminuir monotonicamente no tempo (22). Tal valor pode, ao final do processo, abranger apenas o neurônio central ($N_c = \{c\}$), como se pode observar na Figura 7. A equação 2.2 mostra como são atualizados os pesos do neurônio vencedor e dos neurônios vizinhos.

$$w_{ji}(t+1) = \begin{cases} w_{ji}(t) + \alpha(t)(x_i(t) - w_{ji}(t)), & \text{se } j \in N_c(t) \\ w_{ji}(t), & \text{se } j \notin N_c(t) \end{cases} \quad (2.2)$$

onde $\alpha(t)$ é o valor da taxa de aprendizado $0 < \alpha(t) < 1$, que decresce no tempo.

Como alternativa pode ser introduzida uma função de vizinhança do neurônio vencedor, definido pela seguinte equação, com r_c e r_j como as coordenadas dos neurônios c (neurônio central ou vencedor) e j , respectivamente:

$$h_{ci}(t) = h_0 \exp(-\|r_i - r_c\|^2 / \sigma^2) \quad (2.3)$$

onde $h_0 = h_0(t)$ e $\sigma = \sigma(t)$ são funções que devem decrescer no tempo. O parâmetro $\sigma(t)$ corresponde ao raio de $N_c(t)$. O ajuste de pesos passa então a ser calculado desta forma:

$$w_{ji}(t+1) = w_{ji}(t) + h_{ci}(x_i(t) - w_{ji}(t)) \quad (2.4)$$

Segundo estudos e experiências na escolha dos parâmetros, Kohonen (22) recomenda que o valor inicial de $\alpha(t)$ (taxa de aprendizado da rede) deve estar próximo de 1 e




Figura 7: Exemplo de vizinhança, onde o instante 2 é menor que o instante 1, que por sua vez é menor que o instante 0

decair monotonicamente durante os primeiros 1000 ciclos da fase de aprendizado, porém mantendo o valor acima de 0,1. A regra para o decréscimo de $\alpha(t)$ pode ser uma função linear, exponencial ou inversamente proporcional a t , por exemplo: $\alpha(t) = 0.9(1 - t/1000)$. É durante esta fase inicial do treinamento que ocorre a fase de ordenação da rede. Nas fases seguintes ocorre o ajuste fino da rede, chamado de fase de convergência. O número de ciclos da fase de aprendizado deve ser razoavelmente grande. Uma regra empírica é que este número deva ser 500 vezes maior que o número de neurônios na rede. O tamanho da vizinhança de um neurônio não pode ser muito pequeno inicialmente, pois o mapa não teria uma boa ordenação global. A princípio o raio ou tamanho inicial da vizinhança pode ser maior que a metade do tamanho do mapa.

3 *Modelo proposto*

Este trabalho visa apresentar um modelo para recomendação de filmes para clientes no ambiente de vídeo locadoras. O modelo proposto utiliza as redes SOM como descritas por Kohonen (21) para aprender o comportamento do usuário e auxiliá-lo na escolha do filme.

Após a descrição dos conceitos e algoritmos apresentados no capítulo 2, será apresentado neste capítulo a contribuição do modelo proposto.

3.1 Visão Geral

O modelo para recomendação escolhido leva em consideração a limitação das vídeos locadoras no que tange aos conceitos gerais de sistemas de recomendação comuns. As informações que estão disponíveis num ambiente de locadora de filmes consideram somente o cliente como indivíduo e não um grupo de clientes que podem contribuir juntamente para gerar recomendações. Portanto não há o conceito de avaliação de um item pelo usuário. Nos sistemas de locadoras comuns não existe um mecanismo onde o cliente possa dar sua nota para um filme de forma que outros clientes possam acompanhar essas avaliações e ter um parâmetro para a escolha de determinado título. Existe apenas a opinião "de boca" de clientes que queiram expressar ou quando o funcionário da loja educadamente questiona sobre a satisfação do cliente com relação a determinado filme. Nenhuma informação é armazenada num banco de dados, nem é realizado um levantamento das opiniões de diversos clientes, com o propósito de identificar os melhores filmes.

A proposta deste trabalho é desenvolver um sistema que, baseado no histórico de locações de um cliente, possa conduzi-lo a uma escolha satisfatória no momento de locar um novo título. O sistema se baseia somente no conteúdo dos filmes que já foram locados por um determinado cliente, informações que podem ser facilmente obtidas no banco de dados da locadora. Como mencionado anteriormente, não existem avaliações de clientes

sobre os filmes nem parâmetros que determinem as preferências desses clientes. Portanto, o modelo proposto não ambiciona gerar uma lista de recomendações diretas com títulos para o cliente, apenas auxiliá-lo de forma a realizar uma escolha consciente baseado nas informações contidas nos filmes. O modelo utiliza redes auto-organizáveis pois este algoritmo desempenha bem a função de agrupamento e vizinhança, para que o cliente tenha uma percepção melhor da relação entre os filmes que este já assistiu com os que deseja locar no momento. O objetivo específico do trabalho é realizar uma prova de conceito para o uso de redes SOM na recomendação de filmes a ser implementado em vídeo locadoras como forma de personalização da loja para o cliente, tornando mais prazeroso e simplificado o ato da escolha do filme a ser locado. A personalização torna o cliente mais satisfeito e mais assíduo, podendo ser uma ferramenta no combate à pirataria.

O modelo proposto consiste em uma rede SOM composta por filmes contidos no histórico de um cliente. Existe, portanto, um mapa SOM para cada cliente. A rede irá distribuir os títulos em um mapa bidimensional, agrupando-os de acordo com semelhanças entre informações fornecidas sobre os filmes. Nesta fase ocorre o aprendizado do comportamento do cliente com relação às escolhas de filmes.

Após o treinamento da rede, os filmes locados por um cliente estarão distribuídos no mapa. O cliente deve, então selecionar um filme do acervo da locadora e apresentar ao seu mapa individual. A rede irá calcular a posição deste novo filme e irá mostrar ao usuário 3 filmes que estejam próximos àquele, determinando que há semelhanças entre esses quatro títulos. Esta é uma forma de auxiliar o cliente, pois ele pode avaliar se irá gostar ou não do filme, partindo da satisfação que teve ao assistir os outros três.

3.2 Implementação do modelo

A implementação da rede SOM utilizada no modelo deste trabalho foi feita baseada no algoritmo original proposto por Kohonen, como descrito no Capítulo 2. A tecnologia utilizada para desenvolvimento foi C# com o Microsoft® Visual Studio® 2008 como IDE de programação. A escolha desta tecnologia se justifica por ser uma linguagem de fácil implementação e ser mais largamente utilizada pelo autor deste trabalho. A Figura 8 mostra os diagramas de classes do modelo implementado. MapaSOM é uma classe que comporta todos os neurônios da rede e recebe o conjunto de entradas para ser apresentado durante o treinamento. Cada neurônio possui coordenadas x e y , determinando sua posição no reticulado do mapa e o vetor de pesos que são inicializados aleatoriamente e

ajustados durante a fase de aprendizado. Cada padrão de entrada tem um conjunto de características que são extraídos do banco de dados de filmes, além de um objeto neurônio que caracteriza o neurônio vencedor para representar o padrão.

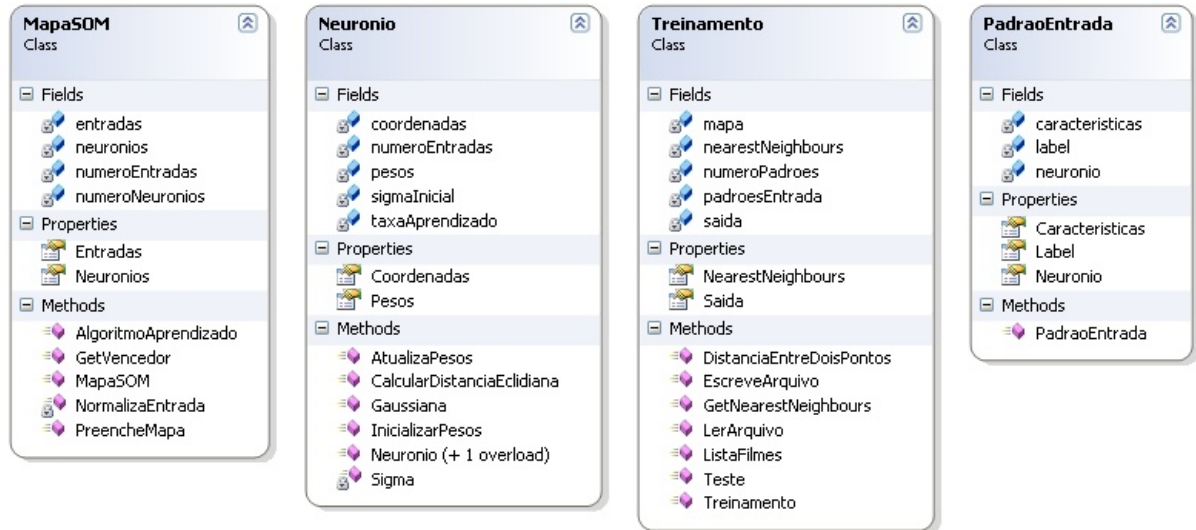


Figura 8: Diagrama de classes do modelo

3.3 Funcionamento do modelo

4 *Experimento e Análise de Resultados*

Este capítulo tem como objetivo descrever os experimentos realizados e resultados obtidos a partir da implementação do modelo descrito no Capítulo 3.

4.1 Base de dados

Como mencionado no capítulo anterior, o objetivo deste trabalho é auxiliar clientes na escolha de filmes em uma vídeo locadora. Foi desenvolvida uma rede auto-organizável, segundo o modelo de Teuvo Kohonen (22), com o fim de aprender o comportamento do usuário e poder guiá-lo em sua escolha. Para a realização dos testes foi utilizada uma base de dados real, extraindo as características que mais se adequam ao modelo proposto.

Inicialmente estava sendo negociada a obtenção dos dados de uma vídeo locadora da cidade, mas devido a entraves na política da empresa que fornece o sistema para esta locadora, não foi possível coletar os dados para teste do sistema. A alternativa encontrada foi utilizar uma base, também real, disponível abertamente na internet. A base de dados utilizada foi a MovieLens Data Set (<http://www.grouplens.org/node/73>), fornecida pelo grupo de pesquisa GroupLens Research. Essa base conta com 100.000 avaliações para 1682 filmes por 943 usuários. A base MovieLens foi construída a partir do sítio de recomendações de filmes: movielens.org. A base de dados MovieLens é assim organizada:

- Arquivo u.data: arquivo contendo 100.000 avaliações de 943 usuários para 1682 filmes. Cada usuário avaliou, no mínimo 20 títulos.
- Arquivo u.itme: contém informações sobre os filmes, título, data de lançamento e gênero.
- Arquivo u.genre: lista de gêneros de filmes.

- Arquivo u.user: informação demográfica sobre os usuários: nome, idade, gênero, profissão.
- Arquivos de treinamento e teste: a base u.data é dividida em dois tipos de arquivos com a relação de 80%/20% para treinamento e teste, respectivamente.

Para o escopo deste trabalho, não serão utilizadas as avaliações dos usuários durante a fase de treinamento, pois foge ao objetivo que é fazer recomendações em ambientes de locadoras de filmes reais, onde não há o conceito de avaliação pelos clientes.

5 Conclusões

Referências

- 1 ANDERSON, C. *A Cauda Longa: do mercado de massa para o mercado de nicho*. [S.l.]: Elsevier, 2006.
- 2 TERVEEN, L.; HILL, W. Beyond recommender systems: Helping people help each other. *HCI In The New Millennium*, Addison-Wesley, 2001.
- 3 LYMAN, P. et al. How much information? 2003. *Technical report*, UC Berkeleys School of Information Management and Systems, 2003. Disponível em: <<http://www2.sims.berkeley.edu/research/projects/how-much-info-2003/>>.
- 4 GOLDBERG, D. et al. Using collaborative filtering to weave an information tapestry. *Communications of the ACM*, v. 35, n. 12, p. 61–70, 1992.
- 5 FILHO, V. M. e-recommender: Sistema inteligente de recomendação para comércio eletrônico. *Trabalho de Conclusão do Curso de Engenharia da Computação*, Universidade de Pernambuco, 2006.
- 6 REATEGUI, E. B.; CAZELLA, S. B. Sistemas de recomendação. mini-curso. Enia, 2005.
- 7 BALABANOVIC, M.; SHOHAM, Y. Fab: Content-based, collaborative recommendation. *Communication of the ACM*, v. 40, n. 3, p. 66–72, 1997.
- 8 GABRIELSSON, S.; GABRIELSSON, S. *The use of Self-Organizing Maps in Recommender Systems*. Dissertação (Mestrado) — Uppsala University, 2006.
- 9 HERLOCKER, J. L. *Understanding and Improving Automated Collaborative Filtering Systems*. Tese (Doutorado) — University of Minnesota, 2000.
- 10 DENNING, P. J. Electronic junk. *Communications of the ACM*, v. 25, n. 3, 1982.
- 11 LANG, K. Newsweeder: Learning to filter netnews. In: *12th International Conference on Machine Learning*. [S.l.: s.n.], 1995.
- 12 KRULWICH, B.; BURKEY, C. Learning user information interests through extraction of semantically significant phrases. In: *AAAI Spring Symposium on Machine Learning in Information Access*. [S.l.: s.n.], 1996.
- 13 BURKE, R. Hybrid recommender systems: Survey and experiments. *User Modeling and User-Adapted Interaction*, v. 12, n. 4, p. 331–370, 2002.
- 14 RESNICK, P. et al. Grouplens: an open architecture for collaborative filtering of netnews. In: *CSCW '94: Proceedings of the 1994 ACM conference on Computer supported cooperative work*. [S.l.: s.n.], 1994. p. 175–186.

- 15 SHARDANAND, U.; MAES, P. Social information filtering: Algorithms for automating "word of mouth". In: *Proceedings of ACM CHI'95 Conference on Human Factors in Computing Systems*. [S.l.: s.n.], 1995. p. 210–217.
- 16 HILL, W. et al. Recommending and evaluating choices in a virtual community of use. In: *CHI '95: Proceedings of the SIGCHI conference on Human factors in computing systems*. [S.l.: s.n.], 1995. p. 194–201.
- 17 CLAYPOOL, M. et al. Combining content-based and collaborative filters in an online newspaper. In: *SIGIR '99 Workshop on Recommender Systems - Implementation and Evaluation*. [S.l.: s.n.], 1999.
- 18 SMYTH, B.; COTTER, P. Personalized electronic program guides for digital tv. *AI Magazine*, American Association for Artificial Intelligence, v. 22, n. 2, 2001.
- 19 BASU, C.; HIRSH, H.; W., C. Recommendation as classification: Using social and content-based information in recommendation. In: *Proceedings of the 15th National Conference on Artificial Intelligence*. [S.l.: s.n.], 1998. p. 714–720.
- 20 BRAGA, A. P.; CARVALHO, A. P. L. F.; LUDERMIR, T. B. *Redes neurais artificiais: teoria e aplicações*. [S.l.]: Editora LTC, 2000.
- 21 KOHONEN, T. *Self-Organizing and Associative Memory*. 3. ed. [S.l.]: Springer-Verlag, 1989.
- 22 KOHONEN, T. The self-organizing map. In: *Proceedings of the IEEE*. [S.l.: s.n.], 1990. v. 78, n. 9, p. 1464–1480.